

Physics-informed deep learning for infectious disease forecasting

基于物理信息的深度学习在传染病预测中的 应用

汇报人: Adrain

JOURNAL OF THE ROYAL SOCIETY
INTERFACE



Physics-informed deep learning for infectious disease forecasting

Ying Qian¹, Kui Zhang¹, Eric Marty², Avranil Basu², Eamon B. O'Dea², Xianqiao Wang³, Spencer J. Fox⁴, Pejman Rohani^{2,5,6}, John M. Drake² and He Li¹

¹School of Chemical, Materials, and Biomedical Engineering, ²Odum School of Ecology and Center for the Ecology of Infectious Diseases, ³School of Environmental, Civil Agricultural and Mechanical Engineering, College of Engineering, ⁴Department of Epidemiology and Biostatistics, ⁵Department of Infectious Diseases, College of Veterinary Medicine, and ⁶Center for Influenza Disease and Emergence Research, University of Georgia, Athens, GA, USA

摘要:

背景: 准确预测传染病对公共卫生政策制定变得越来越重要，精确的预测可以防止数百万人的丧生。为了更好地应对未来的大流行，提高预测方法和能力是至关重要的。

方法: 使用物理信息神经网络 (PINNs)，将疾病传播的动力系统纳入损失函数中，从而利用神经网络结合流行病学理论和数据。为了防止模型过拟合，使用一个额外的子网络来考虑仓室模型中的关键参数，包括流动性、累积疫苗剂量和其他影响传播率的协变量。

结果: 使用加利福尼亚州州级COVID-19数据检验模型表现。结果表明，PINNs模型对病例数、死亡和住院的预测与真实数据相符。特别是，PINNs模型优于简单的基线预测和各种时序深度学习模型，如RNN、LSTM、Transformer等。我们还表明，PINNs模型的表现与复杂高斯感染状态预测模型相当。尽管如此，PINNs模型提供了一个更简单的结构，并且更容易实现。

总之，对PINNs模型在预测传染病动态方面的预测能力进行了系统研究，展示了所提出模型作为提高当前传染病预测能力的有效计算工具的潜力。

研究背景

将PINNs与主流时序深度学习模型的预测性能对比，评估PINNs在传染病多步预测中的优势与局限

传染病预测的紧迫性

- COVID-19已成为2022年美国第三大死因。
- 气候变化预计将加剧疾病传播风险
- 准确预测可为公共卫生决策提供关键支撑，如资源分配、干预措施、疫苗试验等

传统方法的局限

- 仓室模型通常假设传播率、恢复率等参数固定不变，但实际疫情中，参数常因疫苗接种、病毒变异、干预政策等因素动态变化，固定假设难以成立。
- 机器学习能从数据中高效识别规律，可融合多源数据，但需要大量标注训练数据，缺乏传播机制约束，可能产生不合理预测，难以区分真实趋势与数据噪声，预测非平稳系统时表现不佳。

科学机器学习的兴起：PINNs

- 物理信息神经网络将领域知识（如仓室模型ODE）嵌入损失函数
- 融合数据与机理，实现"小数据"学习。
- 可利用物理/生物规律约束，防止过拟合
- 能同时推断未知参数并预测未观测到的动态

数据来源及处理

数据来源


- 每日病例与死亡数：约翰霍普金斯大学CSSE COVID-19数据。
- 每日住院数：美国卫生与公众服务部。
- 移动性：谷歌社区移动报告，住宅停留时间百分比。
- 累积疫苗接种数：约翰霍普金斯大学。

目标变量与时间范围


- 预测目标：每周总报告病例数、死亡数、住院数。
- 时间区间：2020年7月 – 2022年4月，聚焦Beta变异和Delta变异两个主要疫情高峰。
- 住院记录的提供时间晚于病例和死亡数据，可靠的报告始于2020年7月。第110周后数据被舍弃，避免未完整发展的第三峰干扰建模

数据预处理

- 7天移动平均后聚合为周数据。
- 缺失值：疫苗早期缺失值填0，其余线性插值。
- 线性归一化至[0,1]区间，便于训练与可视化。



仓室模型



O'Dea EB, Drake JM. 2022 A semi-parametric, state-space compartmental model with time-dependent parameters for forecasting COVID-19 cases, hospitalizations and deaths. J. R.Soc.Interface 19, 20210702.

仓室模型

$$\frac{dS}{dt} = -\frac{\beta_t SI}{N},$$

$$\frac{dL}{dt} = \frac{\beta_t SI}{N} - \eta L,$$

$$\frac{dI}{dt} = \eta L - \gamma I,$$

$$\frac{dC}{dt} = [p_h + \rho_t(1 - p_h)]\gamma I - \gamma_{z,w}C,$$

$$\frac{dC_r}{dt} = \gamma_{z,w}C,$$

$$\frac{dH}{dt} = p_h\gamma I - \gamma_h H,$$

$$\frac{dA}{dt} = p_h\gamma I,$$

$$\frac{dD}{dt} = p_d\gamma_h H - \gamma_{d,w}D,$$


$$\frac{dD_r}{dt} = \gamma_{d,w}D.$$

采用O'Dea & Drake (2022) 提出的 COVID-19 半参数状态空间仓室模型，S是易感者，L是潜伏者但不具备感染性，I是感染者，C是被确诊还尚未报告的人， C_r 是新报告的病例数，H是住院的人数，A是新住院人数，D是已死亡还尚未报告人数， D_r 是新报告的死亡人数。

name	definition	value
β_t	transmission rate	estimated
N	population size	39 512 223 persons
η	incubation rate	365.25/4/year
γ	removal rate	365.25/4/year
$\gamma_{d,w}$	rate of reporting deaths on day of week w	365.25/10/year
$\gamma_{z,w}$	rate of reporting cases on day of week w	365.25/1/year
γ_h	rate of exit from hospital	365.25/10/year
p_h	probability of an infection leading to hospitalization	estimated
p_d	probability of a hospitalization leading to death	estimated
ρ_t	probability of a removal on day t being reported as a case	0.5

物理信息神经网络

核心思想： 将仓室模型与观测数据同时嵌入神经网络的损失函数中，实现机理驱动与数据驱动的融合。



上层子网络（状态变量预测）

输入时间 t ，3个隐藏层，每层50个神经元，输出9个仓室状态变量，输出经指数变换确保正值，全部9个变量参与计算ODE损失 L_{ODE}

下层子网络（时变参数估计）

输入时间 t ，3个隐藏层，每层50个神经元，输出3个时变参数，传染率参与计算ODE损失 L_{ODE} ，移动性、累积疫苗接种参与数据损失 L_{data}

损失函数

通过将ODE损失与数据损失相结合，将仓室模型施加的约束集成到PINNs训练过程中。具体地，总损失被定义为数据损失和ODE损失的加权和：

$$\mathcal{L} = \mathcal{L}_{\text{data}} + w_{\text{ODE}} \cdot \mathcal{L}_{\text{ODE}} + \lambda \cdot L_2$$

数据损失 L_{data} ：度量网络预测值与真实观测值之间的差距，仅针对有观测数据的变量。

$$\begin{aligned} \mathcal{L}_{\text{data}} = & \underbrace{\frac{1}{N_{C_r}} \sum_{i=1}^{N_{C_r}} |y_{\theta_u}^5(t_i^C) - C_{r,i}|^2}_{\text{病例拟合}} + \underbrace{\frac{1}{N_A} \sum_{i=1}^{N_A} |y_{\theta_u}^8(t_i^A) - A_i|^2}_{\text{住院拟合}} + \underbrace{\frac{1}{N_{D_r}} \sum_{i=1}^{N_{D_r}} |y_{\theta_u}^9(t_i^D) - D_{r,i}|^2}_{\text{死亡拟合}} \\ & + \underbrace{\frac{1}{N_M} \sum_{i=1}^{N_M} |z_{\theta_l}^1(t_i^M) - M_i|^2}_{\text{移动性拟合}} + \underbrace{\frac{1}{N_V} \sum_{i=1}^{N_V} |z_{\theta_l}^2(t_i^V) - V_i|^2}_{\text{疫苗拟合}} \end{aligned}$$

数据损失 L_{ODE}

目的：强制神经网络的输出满足仓室模型的9个常微分方程，使预测在物理上合理。

$$\mathcal{L}_{ODE}(\theta) = \mathcal{L}_0(\theta) + \mathcal{L}_r(\theta),$$

初始条件损失 $\mathcal{L}_0$

作用：约束网络在起点的输出与已知初始值一致

$$\mathcal{L}_0 = \sum_{j=1}^9 \left| y_{\theta_u}^j(t_0) - I_j \right|^2$$

符号	含义
$y_{\theta_u}^j(t_0)$	上子网络在 t_0 时刻的第 j 个状态变量预测值
I_j	文献[22]给出的第 j 个状态的初始值（9个值均预设）
求和范围	全部9个状态变量 $S, L, I, C, C_r, H, A, D, D_r$

残差损失 $\mathcal{L}_r$

作用：网络输出对ODE系统的违反程度，即方程左右两边之差的平方。


$$\mathcal{L}_r = \sum_{j=1}^9 \frac{w_j}{N_{ODE}} \sum_{i=1}^{N_{ODE}} |R_j(t_i; \theta)|^2$$

残差计算示例（第1个方程： $dS/dt = -\beta_t SI/N$ ）：


$$R_1(t_i) = \underbrace{\frac{dy_{\theta_u}^1(t_i)}{dt}}_{\text{自动微分求解}} + \underbrace{\frac{z_{\theta_l}^3(t_i) \cdot y_{\theta_u}^1(t_i) \cdot y_{\theta_u}^3(t_i)}{N}}_{\text{右端项代入网络输出}}$$

若预测完全满足ODE，则 $R_1 = 0$


滚动窗口




用第1~17周数据训练 → 预测第18~21周



扩展至第1~18周 → 预测第19~22周



重复至第1~89周 → 预测第90~93周



每个未来第1/2/3/4周均有预测值

time (week)

 training data  1 week predictions  2 week predictions  3 week predictions  4 week predictions

评价指标

评价类型	指标	解决问题
点预测	MASE	模型预测的“最佳估计值”准不准
概率预测	WIS	模型给出的“预测区间”好不好

MASE

把模型的MAE除以一个“朴素基线模型”的MAE

$$\text{MASE} = \frac{\text{MAE}_{\text{模型}}}{\text{MAE}_{\text{朴素模型}}} \quad \text{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i|$$

朴素模型：前几周的值对应后几周的预测值

- MASE<1:模型优于基线
- MASE=1:模型与基线持平
- MASE>1:模型不如基线

MASE越小，模型越好

WIS

假设预测结果符合正态分布

$$Q(p) = \mu_t + \sigma \cdot \sqrt{2} \cdot \text{erf}^{-1}(2p - 1)$$

对于给定的预测区间[L,U]，置信区间是 $(1-\alpha)$ ，预测值的得分U-L+超界惩罚

$$\frac{2}{\alpha}(L - y) \quad \frac{2}{\alpha}(y - U)$$

WIS计算所有区间的得分为模型的得分
使用模型的WIS除以朴素基线模型的WIS
WIS越小，模型效果越好

消融实验

Ablation Study是控制变量法，每次移除模型的一个组件，观察性能变化，从而理解每个组件的贡献。

实验一
对比PINNs和NN

实验二
对比PINNs和GISST

实验三
对比不同时间窗口
16周窗口最优。

实验四
正则化的作用

method	MASE			WIS			scaled WIS		
	cases	deaths	hosp	cases	deaths	hosp	cases	deaths	hosp
PINNs: one week	0.75	1.00	0.58	16 247	103	250	0.70	1.04	0.57
PINNs: two week	0.77	0.92	0.62	32 954	146	556	0.79	1.00	0.66
PINNs: three week	0.81	0.86	0.68	49 272	176	882	0.87	0.91	0.72
PINNs: four week	0.85	0.89	0.74	63 311	217	1232	0.94	0.89	0.79
NN: one week	0.91	1.32	0.65	25 152	158	298	1.09	1.60	0.68
NN: two week	1.27	1.76	0.79	52 761	298	729	1.27	2.04	0.86
NN: three week	1.56	1.86	0.89	88 920	442	1281	1.57	2.29	1.05
NN: four week	1.65	1.84	0.97	1 18 515	558	1885	1.76	2.28	1.22
GISST: one week	0.85	0.88	0.91	15 346	163	401	0.66	1.65	0.92
GISST: two week	0.75	0.64	0.78	26 233	185	798	0.63	1.27	0.94
GISST: three week	0.71	0.45	0.77	37 041	187	1300	0.65	0.97	1.06
GISST: four week	0.76	0.34	0.89	58 148	181	2159	0.86	0.74	1.39

实验环境

项目	设置
优化器	Adam
学习率	0.001
训练轮数	50,000
正则化系数	1×10^{-5}
硬件	NVIDIA GeForce RTX 3090 GPU


超参数	搜索范围	最终选择
学习率	$10^{-5} \sim 10^{-1}$	10^{-3}
隐藏层数	2 ~ 5	3
每层神经元	20 ~ 100	50
训练轮数	10,000 ~ 200,000	50,000
正则化系数	$10^{-10} \sim 10^{-1}$	10^{-5}
损失权重	$10^{-5} \sim 1$	0.1

结果

点预测

预测结果表明PINNs的输出与观察到的目标值一致，并且在所有预测范围内都比朴素模型的预测更准确。此外，PINNs在大多数时候比GISST表现更优。结果还表明，一周前的预测是最可靠的，随后两周、三周和四周的预测准确性逐渐下降。随着预测范围的增加，预测值倾向于与真实值偏差更大，同时预测曲线的波动也更大。

PINNs的所有MASE分数均不超过1.0，这表明PINNs在所有预测范围内都持续优于朴素模型。在三个状态变量中，死亡数的MASE分数通常高于病例和住院数，这可能是由于原始死亡数据中变异性和大小的波动更大。




结果

区间预测

对于每组1到4周的预测，随着预测范围的扩大，代表分位数=0.5的中位数预测点逐渐偏离真实值。相应地，代表预测不确定性的浅蓝色区域随着预测范围的延长而扩大。说明随着预测范围的增加，预测精度降低，不确定性增加。

PINNs的WIS通常低于1.0，这表明在大多数预测范围内，PINNs的性能优于朴素基线。唯一的例外是在死亡预测的一周前分位数预测中，PINNs的WIS分数略高于1.0。然而，这种偏差很小，仍然显著低于其他模型的分数。





结果

PINNs与时序深度学习对比

PINNs的MASE和WIS得分在每个预测时域上均低于NN的相应得分，这证明了PINNs在点预测和分位数预测方面相对于NN的绝对优势。这可能是由于分室模型的正则化效应。

与PINNs相比，RNN、LSTM、GRU和transformer生成的预测显示出明显的波动，表明过拟合的程度更高。这种对比突出了将物理信息纳入PINNs的优。PINNs在点预测的MASE和分位数预测的WIS方面，始终优于所有其他常用的用于时间序列预测的突出NN模型。这些发现强调了将基于物理的领域知识整合到NN模型中对于提高泛化能力和预测准确性的重要性。





讨论与总结

模型	方法	优势	局限
传统机制模型	仓室模型+参数估计	可解释性强， 物理意义明确	参数参数常假设固定， 难以适应真实变化
数据驱动模型	LSTM、Transformer	灵活、能捕捉复杂非线性	需要大量数据， 可解释性差， 预测可能不合理

PINN通过将仓室模型嵌入损失函数来整合特定领域的知识，有助于减轻过度拟合，在灵活性和可推广性之间实现了平衡。

PINNs可以用来直接从数据中估计关键流行病学参数，如传播率和恢复率，捕捉传播行为的时间变化，从而增强模型对疾病动态变化的适应性。

此外，PINNs能够持续整合新获得的数据，允许实时模型更新，并在更多信息在持续爆发期间变得可用时，逐步提高预测的准确性。



PINNs可以整合异构数据源，包括社会、环境和人口因素，为传染病预测提供一个更全面和整体性的框架。

与现有工作的对比

维度	现有工作	本文工作
仓室模型复杂度	较简单	高维ODE
预测目标数量	通常预测一个变量	同时预测三个变量
评价指标	点预测	点预测+区间预测
性能对比	本研究模型性能更好	

研究的局限

尽管估计的传播率在观测数据的合理范围内，但趋势与真实参考值不吻合。这可能是由于常微分方程系统包括九个状态变量，但其中只有三个与观测数据相关。这三个观测数据不会直接影响包含传播率的常微分方程。但加入少量真实传播率观测点后，模型即可捕捉其动态趋势。



Bayesian physics-informed neural networks


Journal of Computational Physics 425 (2021) 109913



Contents lists available at [ScienceDirect](https://www.sciencedirect.com)

Journal of Computational Physics

www.elsevier.com/locate/jcp



B-PINNs: Bayesian physics-informed neural networks for forward and inverse PDE problems with noisy data



Liu Yang^{a,1}, Xuhui Meng^{a,1}, George Em Karniadakis^{a,b,*}

^a Division of Applied Mathematics, Brown University, Providence, RI 02912, USA

^b Pacific Northwest National Laboratory, Richland, WA 99354, USA